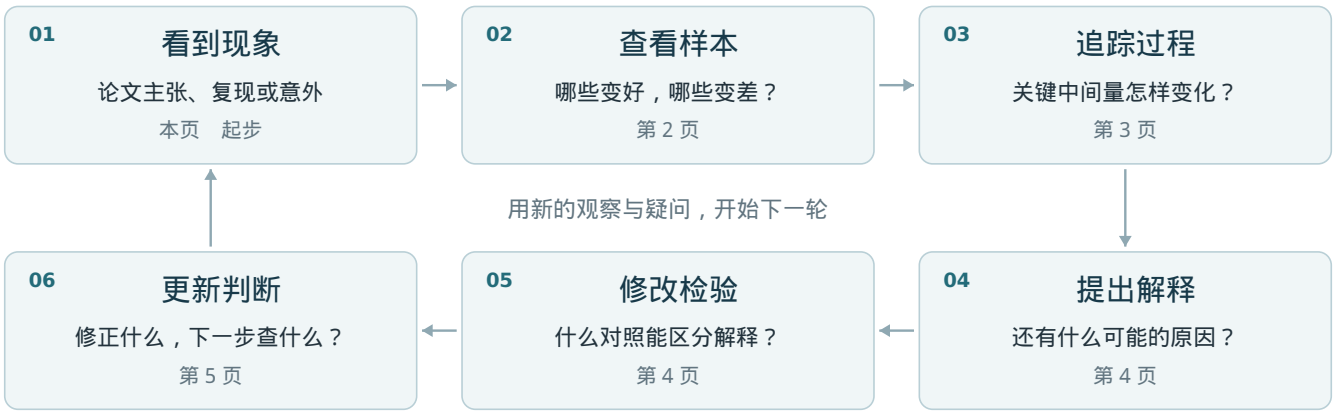
带着问题做研究

从复现与观察，到实验判断与讨论

让每次动手都增加一点理解，并能据此提出下一个有理由的问题。

开始前先问 当前最关键的未知是什么，为什么值得弄清？哪项小检查能帮助我决定下一步？[4]

顺着证据提出下一个问题



按当前卡点进入，每次选两三个问题，不必依次完成。有预期先记录；没有预期，就写明想观察什么。完成一轮后，用第 6 页回顾自己的经历。

读论文与复现，先回答五个问题

主张与证据 作者想说明什么？哪项比较支持它？哪些结论已经得到支持，哪些仍只是解释或猜测？

复现目标 这次要复现一个数值、一条趋势，还是一个关键现象？它能帮助我回答什么研究问题？

比较条件 数据、模型、预算和评测口径是否可比？基线是否充分实现与调参？哪些未对齐的条件可能影响结论？

结果可信性 我能解释指标吗？小例子与简单基线说得通吗？实际输入、执行和评分检查过了吗？

差异定位 结果不一致时，能否缩小到某一步、某类样本或某项设置？哪些已有证据，下一项最有用的检查是什么？

> 做完应能回答 论文支持什么，这次复现了什么；比较是否可信，剩余差异下一步怎么查。

从分数回到具体样本

核心问题 哪些情况发生了什么变化？

总体指标给出一个比较结果。理解这个结果，需要亲自查看普通样本、成功与失败案例，以及两种方法在同一样本上的得失。[2][3]

先确认自己看见了什么

任务实际是什么 看一批普通样本，我能判断什么结果算好吗？标签、评分和这个判断是否一致？

变化落在哪里 在同一批样本上，哪些变好、哪些变差、哪些不变？收益和退步是否在平均数里抵消了？

什么出乎意料 相近的成功与失败案例差在哪里？有没有与当前理解不一致的结果？表现特别好时，也能解释为什么好吗？

再把个例变成可以检查的规律

能否说得更具体 差异是否集中在某种输入、条件或阶段？能否把肉眼观察写成一个可统计的特征？

范围有多大 一共看了多少样本，怎样选的？这个现象涉及多少样本，在普通样本中有多常见？

有没有反例 哪些样本不符合这条规律？反例是在否定解释，还是提示它只在某些条件下成立？

可以先随机看一批，再对照几组条件相近但结果不同的案例，最后检查现象的范围。挑选出来的案例可以提供线索，不能直接代表总体发生率。

差异可靠吗

能否反复看到 在相同样本、可比条件下重复比较，差异是否稳定？换一批数据后还会出现吗？

不确定性来自哪里 来自运行的随机性、样本的有限性，还是测量方式？当前检查覆盖了哪一种，仍遗漏了什么？

证据够到哪一步 现在足以说明存在一个值得追查的现象，还是已经足以支持更一般的结论？

需要报告差异时，保留样本数、重复次数和差值的不确定性。重复运行与重采样回答的问题不同；重采样的单位也应符合数据结构。不能仅凭两次均值，或把单个方法的波动直接当作方法差异的判断标准。

> 接下来怎么走 选一个最值得解释的变化，进入真实输入、执行过程和中间结果，检查它是怎样产生的。

> 做完应能回答 变化发生在什么样本与条件下，证据有多可靠；哪些是规律，哪些还只是线索。

沿着实际过程理解方法

核心问题 这个结果是怎样产生的？

选一个你想解释的结果，沿它的执行路径读代码。把论文里的设计、代码中的实现和运行时的数据对应起来，逐步弄清关键环节。[1][2]

用一个真实样本串起关键步骤

完整路径 从输入到输出，经过哪些关键步骤？每一步解决什么问题，为什么需要它？

实际收到什么 我检查的是原始数据，还是模块真正收到的输入？预处理、拼接、压缩或筛选改变了什么？

设计在哪里发生 论文强调的模块在哪段代码执行？实际收到什么、产生什么？是否符合我对方法的理解？

最早的分歧 同一样本的两次运行最早从哪里不同？最后一处符合预期、第一处偏离预期分别在哪里？

该看哪个中间量 要区分当前的猜测，最需要观察什么？这个中间量为什么有判断价值？

怎样传到结果 中间的变化被后续放大、抵消，还是根本没有影响最终输出与评分？

复杂到看不清时，把问题缩小

能否缩短流程、减少输入或固定一部分因素，同时保留要研究的现象？在这个简单情形下，能否手工核对关键步骤？能否构造一个应该成功的情形，再构造一个让问题更明显的情形？[1]

还不熟悉系统时，可以先探索

暂时提不出机制解释也没关系。可以先问：系统对哪些变化敏感？哪些设置变化很大，输出却几乎不变？哪些行为和直觉相反？围绕一个因素做小范围尝试，记录响应，再决定什么值得深入。

目标是逐渐能够预测和定位。关键代码要能说明作用，关键行为要经过检查；不需要把读完整个仓库当作开始实验的前提。

> 注意证据的边界 最早出现分歧的位置和异常中间量，给出了检查线索。要判断它们是否造成最终变化，还需设计相应对照。

> 做完应能回答 我能用具体样本解释关键处理过程，指出已经理解的环节、仍有疑问的位置，以及下一项需要观察的量。

用修改检验自己的解释

核心问题 改变什么，能让不同解释给出不同预测？

运行前先说清三件事

观察与解释 我直接看到了什么？据此猜测什么？还有哪些原因也能产生相同现象？

修改与对照 准备改什么、保持什么、观察什么？怎样确认改动真正执行，没有同时改变关键的比较条件？

预期与反证 如果解释成立，哪个中间行为应先变，最终结果会怎样？出现什么结果，我会修正或放弃它？

能预测到哪一步，就写到哪一步；不确定方向或幅度，要如实说明。如果是在探索，先写清希望认识哪一种响应。

选择能回答问题的改法

改法	它主要帮助回答什么
移除或绕过 消融 / ablation	当前条件下，哪些行为依赖这一部分？
换成简单替代	复杂设计比简单规则多解决了什么？
打乱或替换信息	效果依赖有效内容，还是只依赖存在、形式或规模？
逐渐改变强度	作用从何时出现，何时饱和、反转或损害其他表现？
换成理想化结果 oracle	这一环节变好后，后续能否利用？瓶颈是否还在别处？

定位单个因素时，先做容易解释的对照；怀疑相互作用时，比较因素分别改变与共同改变的情况。测试时关闭模块可能引入分布变化；理想化替换用于诊断，不自动构成性能上界。

结果出来后，继续追问

符合预期吗 中间行为是否按预测变化？效果是否集中在预期的样本上？哪些结果仍解释不了？

分数不变说明什么 是没有作用、收益与退步抵消，还是改动太弱、样本太少或指标不敏感？下一项检查能区分什么？

能排除到哪里 修改后变好，是否仍有其他解释？一次失败否定的是当前实现，还是更一般的思路？

> 做完应能回答 这次修改检验了什么，支持或削弱了哪个解释，哪些仍不能区分，以及下一项小实验为何值得做。[4]

让每轮工作增加一点认识

核心问题 相比上次，我现在能回答什么？

把结果变成有边界的判断

认识改变了什么 原先怎样理解，现在怎样理解？哪条证据让我改变了判断？没有提升时，是否也排除了一个解释？

能否预测新情况 按修正后的认识，我预计在一个尚未检查的样本或条件下会发生什么？再用结果检查它。

是否值得深挖 这是实现、评价的问题，还是方法本身的局限？出现多广、影响多大、对谁重要？已有工作解释到了哪里？

下一步为什么做它 当前最关键的未知是什么？哪项最小验证可能改变方向，或帮助判断是否值得投入更多资源？

在开发数据上发现规律、选择分组和调整方法，再用未参与这些选择的数据检查结论。暂时无法推广时，把结论限定在已有证据覆盖的条件内。

平时留下记录，回顾才有依据

每轮至少留下：问题与运行前想法；实际设置与结果位置；观察、解释和判断变化；下一项检查。定期回看反复猜错的地方，把经验写成带适用条件的认识。[5]

汇报时，让听者能够参与判断

顺序	要说清的内容
1 问题	上次要弄清什么，这次重点回答哪一点？
2 发现	最重要的新认识是什么，哪些仍未解决？
3 证据	哪张图、哪组比较或哪个样本支持它？条件与范围是什么？
4 解释	哪些是事实、哪些是猜测，证据还缺在哪里？
5 决定	我建议怎样继续，最需要大家帮助判断什么？
6 下一步	讨论后做哪项检查，什么结果会改变判断？

会前按约定发出简短材料。每张图先说它回答什么，再解释关键比较；准备好对应的样本与运行记录。讨论结束后，写下达成的判断、分歧和下一步。[6]

卡住时，带着已经知道的部分求助

先缩小问题、查文档和日志，给自己设一个与任务相称的时限。持续没有新信息时就求助，不必等到组会。说明目标、预期、实际现象、已做检查及证据，以及最希望对方帮忙判断的地方。

写下你自己的研究回顾

完成一轮实际工作后，用真实经历串起这条研究过程。[5][6]

选一次真实经历：复现差异、意外结果，或一次没有提升的尝试。
在此简写，或另写半页到一页；附上证据链接或记录编号。

> 先看当时的记录 运行前有记录，就按记录写；没有记录，写“当时未记录”。现在形成的解释另写，不要把事后的理解当作原来的预测。

1 我当时想弄清什么

为什么选这个问题？最初不知道什么？

2 我实际看到了什么

最关键的结果或样本是什么，证据在哪里？哪些是观察，哪些是解释？

3 我怎样从结果追到过程

查了哪段代码或哪个中间量？哪项检查缩小了问题，哪项没有带来新信息？

4 我怎样修改，运行前怎么想

改了什么、保持了什么？当时的预期有无记录？这项对照想区分哪些解释？

5 结果怎样改变了我的判断

哪个猜测受到支持或挑战？还有什么解释没排除？哪些反例仍解释不了？

6 接下来怎样推进，需要讨论什么

下一项最有价值的检查是什么？先写下预期或未知，以及希望得到的帮助。

保留走弯路、猜错和未完成的部分。不必每一项都写满；重点是让别人看见证据如何推动了你的判断。下次回看时，再补上新的认识。

让结果可信，继续读下去

正文关注怎样推进；这些检查帮助你确认推进所依据的结果可靠。

可追溯 保留代码版本、配置、数据、运行命令和相关随机种子；保存关键输入、中间结果与输出，不覆盖旧结果。

先小后大 先用小规模与答案已知的情形检查流程和指标，再扩大运行；用简单基线核对结果是否合理。

好坏都查 结果异常好同样要核查实现、配置和评测；排除数据泄漏，确认比较条件和改动确实生效。

留出验证 记录案例与分组的选择过程；用于最终验证的数据不参与方法选择和调参。

AI 辅助 关键代码要能解释作用并核验实际行为；影响判断的资料回原文确认，未验证部分明确保留为限制。

参考阅读

建议先读 [1]，再按卡点选读。以下是原文阅读重点；正文的问题与练习由这些经验启发并重新组织，并非逐条翻译。

[1] Bill Freeman · How to do research

https://people.csail.mit.edu/billf/publications/How_To_Do_Research.pdf
看假设核验、简单模型和失败定位：怎样把“不起作用”推进到可检查的问题。

[2] Mark Dredze · Hanna M. Wallach · How to Be a Successful PhD Student

https://www.cs.jhu.edu/~mdredze/publications/HowtoBeaSuccessfulPhDStudent.1_2.pdf
优先看 Know your data、Know your software、Good baselines 与 Understand your results。

[3] Andrej Karpathy · A Recipe for Training Neural Networks

https://karpathy.github.io/2019/04/25/recipe/
看 The recipe 开头及第 1、2 节：检查真实数据，从简单情形逐步核验。

[4] Jacob Steinhardt · Research as a Stochastic Decision Process

https://cs.stanford.edu/~jsteinhardt/ResearchasaStochasticDecisionProcess.html
看 opening up the task black box 和实用建议：先用小检查减少关键未知。

[5] Jason Eisner · How to Do Research With a Professor

https://www.cs.jhu.edu/~jason/advice/how-to-work-with-a-professor.html
看 Experimental logbook 与 Working With Others：把问题、结果和分析连起来。

[6] Michael Ernst · Writing a progress/status report

https://homes.cs.washington.edu/~mernst/advice/progress-report.html
全文很短：围绕进展、下一步与讨论议程汇报，平时记录，回顾时有据可查。